Introduzione alla Statistica Matematica

Note del Corso

Francesco Grotto, Mario Maurelli, Maurizio Pratelli



Front Page Photo ©Filippo Poli,
CC BY-SA 4.0 <https://creativecommons.org/licenses/by-sa/4.0>, via Wikimedia Commons

LaTeX template ©Mathias Legrand (legrand.mathias@gmail.com),
CC BY-NC-SA 3.0 <http://creativecommons.org/licenses/by-nc-sa/3.0>,
via http://www.LaTeXTemplates.com

The following notes are licensed under
`https://creativecommons.org/licenses/by-nc-sa/4.0/` (CC BY-NC-SA 4.0)
Creative Commons Attribution-NonCommercial-ShareAlike 4.0 International



Non è consentito distribuire o utilizzare a fini commerciali i contenuti che seguono.

Indice

I Statistica Descrittiva

1 Statistiche Riassuntive e Grafici 7
1.1 Campioni, grafici a barre, istogramma 7
1.2 Indici statistici 10
1.3 Funzione di ripartizione empirica 13
1.4 Percentili, Quantili e Boxplot 13

2 Dati Multivariati 17
2.1 Covarianza e correlazione campionarie 17
2.2 La retta di regressione 18

II Probabilità

3 Probabilità e (In)dipendenza 23
3.1 Spazi di Probabilità 24
3.2 Calcolo Combinatorio 27
3.3 Probabilità Condizionata e formula di Bayes 28
3.4 Indipendenza 31
3.5 Probabilità sulla retta reale 33
3.6 Esercizi 35

I Statistica Descrittiva

1 Statistiche Riassuntive e Grafici 7
1.1 Campioni, grafici a barre, istogramma
1.2 Indici statistici
1.3 Funzione di ripartizione empirica
1.4 Percentili, Quantili e Boxplot

2 Dati Multivariati 17
2.1 Covarianza e correlazione campionarie
2.2 La retta di regressione

1. Statistiche Riassuntive e Grafici

La statistica si occupa dello studio di dati, ovvero della loro raccolta –questione di cui queste note non si occupano– e della loro analisi ed interpretazione. Le risposte di tale analisi, tramite i metodi matematici di cui il seguito dà una introduzione elementare, non dipendono solo dai dati in se, ma dalla conoscenza pregressa del problema studiato e quindi dalle eventuali ipotesi ed assunzioni che entrano a far parte del modello matematico usato.

Si parla di **statistica descrittiva** quando i dati vengono analizzati, seppur con tecniche anche raffinate, senza fare assunzioni esterne all'insieme di dati considerati. Lo scopo è quindi l'organizzazione dei dati in modo da evidenziarne la struttura, e di rappresentarli in modo efficace. Di questo ci occuperemo brevemente in questa prima parte delle note.

L'**inferenza statistica** invece studia i dati utilizzando un modello probabilistico, cioè suppone che i dati siano valori assunti da **variabili aleatorie** aventi una certa **distribuzione di probabilità** dipendente da dei parametri non noti. In questo caso, l'analisi statistica ha come scopo la stima di questi parametri, ed il modello matematico che risulta da tale stima può essere utilizzato per fare delle previsioni ed informare delle decisioni. La definizione matematicamente rigorosa di questi concetti è il tema principale di questi appunti. Chiaramente conclusioni più forti dell'analisi dei dati seguono a prezzo di assunzioni più stringenti e dettagliate, che quindi rischiano di essere meno affidabili e non sempre verificate.

Non ci occuperemo della **statistica bayesiana**, un terzo approccio al problema dell'analisi dei dati, che però citiamo per l'importanza nelle applicazioni.

1.1 Campioni, grafici a barre, istogramma

I dati che ci proponiamo di analizzare altro non sono che risultati numerici di misure ripetute. Si considera cioè una **popolazione**, l'insieme di oggetti o fenomeni che si vuole studiare, su ognuno dei quali è possibile effettuare la stessa misura, ovvero considerarne un **carattere**. La popolazione può essere reale, ad esempio la popolazione italiana, un'urna con 10 biglie, oppure può essere ideale, ad esempio, per un esperimento fisico ripetuto più volte, la popolazione è data da "tutte le infinite possibili ripetizioni dell'esperimento"). Un **campione statistico** (*statistical sample*) è un sottoinsieme della popolazione scelto per rappresentarla. I nostri **dati** consistono nelle

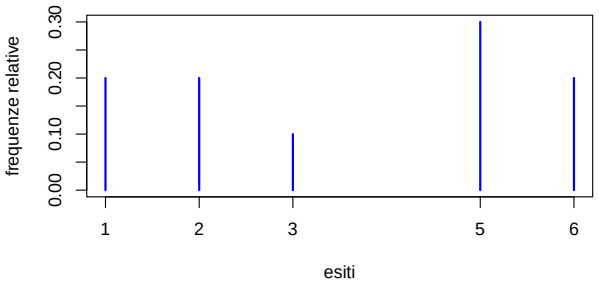
misure effettuate su di esso (spesso nell'impossibilità di effettuare la misura sulla totalità della popolazione).

Il carattere la cui misura sul campione costituisce l'insieme dei dati può essere quantitativo o qualitativo. Un carattere **quantitativo** è una quantità numerica, ovvero *gli esiti della misura sono numeri paragonabili tra loro*, come ad esempio l'altezza di una persona o il prezzo di un oggetto. Un carattere **qualitativo** invece produce misure che non possiamo paragonare tra loro in modo significativo con dei numeri: ad esempio il carattere "nome proprio di una persona" può anche essere riassunto numerando tutti i nomi (ad esempio in ordine alfabetico), ma questi numeri non misurano il modo in cui i diversi nomi differiscono.

Dato un possibile esito della misura (qualitativo o quantitativo), la sua *frequenza* (assoluta) è il numero di volte in cui questo esito compare nei dati, mentre la *frequenza relativa* è la frazione (di solito percentuale, per comodità) di volte in cui questo esito compare sul totale dei dati.

La situazione forse più semplice da rappresentare è quella in cui l'esito della misura di un carattere può assumere una quantità finita e relativamente piccola di valori (qualitativi o quantitativi); parliamo in questo caso di **carattere discreto**. In questo caso, per rappresentare la distribuzione dei dati possiamo usare un **diagramma a barre**, che consiste in una serie di barre verticali, ciascuna delle quali ha altezza pari (o proporzionale) alla frequenza relativa di un possibile esito della misura. Un altro modo di rappresentare questi dati è il diagramma a torta (*piechart*).

■ **Esempio 1.1 — Caratteri Qualitativi, Diagramma a Barre.** Lanciamo un dado (non necessariamente equo) 10 volte. Gli esiti possibili sono $1, 2, \dots 6$, la popolazione (ideale) è costituita da tutti i possibili lanci del dado, mentre il campione è dato dai 10 lanci effettuati. Supponiamo di ottenere i seguenti esiti: $6, 2, 3, 1, 2, 5, 6, 5, 5, 1$. Il diagramma a barre è il seguente:

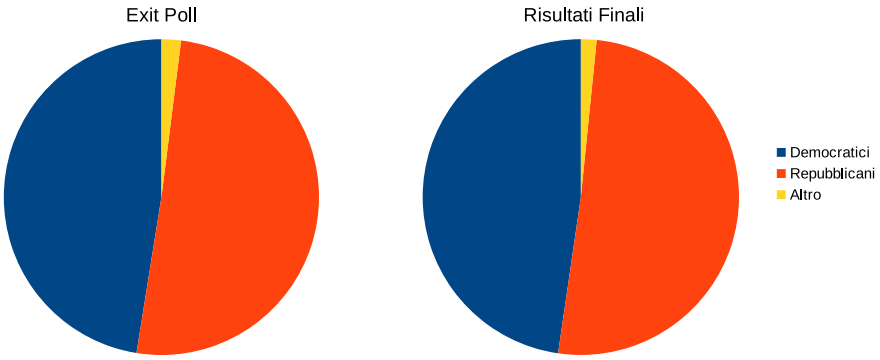


■

Notiamo che le frequenze e quindi anche la loro rappresentazione dipendono dai dati del campione scelto e non coincidono in generale con le frequenze su tutta la popolazione.

■ **Esempio 1.2 — Caratteri Qualitativi, Campione vs. Popolazione.** Un *exit poll* è un sondaggio sul voto espresso condotto tra votanti che hanno appena lasciato il seggio elettorale. Gli esiti possibili sono i partiti o i candidati in corsa, e il campione è una parte di solito molto ridotta della popolazione (che è l'insieme di tutti i votanti), tanto che spesso se ne discute la rappresentatività.

Alle *midterm elections* statunitensi, il 9 Novembre 2022, un *exit poll* della CNN ha intervistato 18571 persone, che alla Camera hanno votato i Democratici per il 47.47% oppure i Repubblicani per il 50.53% (il 2% altro). Abbiamo in questo caso il vantaggio di poter confrontare una misura su (quasi) tutta la popolazione: il risultato generale ha visto i Democratici al 47.7% e i Repubblicani al 50.7% (1.6% altro).



Vediamo dunque che la frequenza di un carattere in un campione non coincide con quella su tutta la popolazione. ∎

Si pone quindi il problema di come scegliere il campione in modo che sia rappresentativo: benchè sia una questione molto importante e complessa nelle applicazioni, non rientra negli obbietivi di queste note. Ci limitiamo a menzionare che nella statistica inferenziale, oggetto principale di questi appunti, è sottointesa l'assunzione di avere a disposizione un campione "scelto a caso uniformemente" nella popolazione: vedremo quanto questo potrà essere informativo, cioè quanto questa ipotesi permetta di dedurre, assieme al dato del campione, informazioni sulle frequenze di tutta la popolazione.

Tornando alla rapprentazione dei dati, vi sono casi in cui i risultati possono assumere un gran numero di valori quantitativi: ad esempio se misuriamo la temperatura (in Kelvin) di un certo gas, questa può assumere un qualunque valore positivo. In casi come questo parliamo di **carattere continuo**. Poiché i dati possono essere tutti diversi tra loro, ha poco senso considerare la frequenza di un singolo esito. La rappresentazione grafica più immediata usata in questo caso è l'**istogramma**[1]. Quest'ultimo consiste in una serie di colonne, ognuna delle quali ha per base un intervallo numerico e per *area* la frequenza relativa dei dati contenuti in quell'intervallo[2].

Altezza	Frequenza Assoluta
1.55-1.58	2
1.58-1.61	5
1.61-1.64	12
1.64-1.67	25
1.67-1.70	58
1.70-1.73	41
1.73-1.76	43
1.76-1.79	7
1.79-1.82	6
1.82-1.85	1

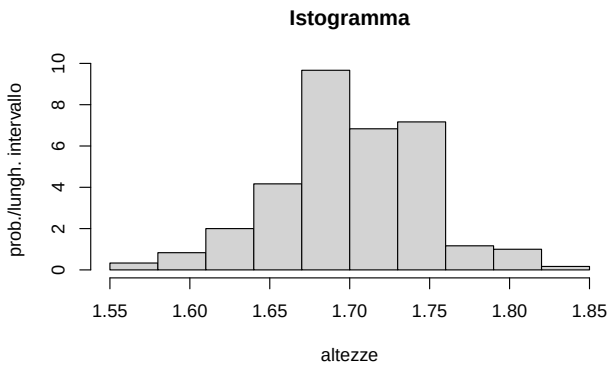


Figura 1.1: Le frequenze assolute delle altezze (in metri) di 200 persone (dati inventati), e il relativo istogramma.

[1] Parola grecizzante coniata da Karl Pearson per indicare questi "grafici a bastoni".

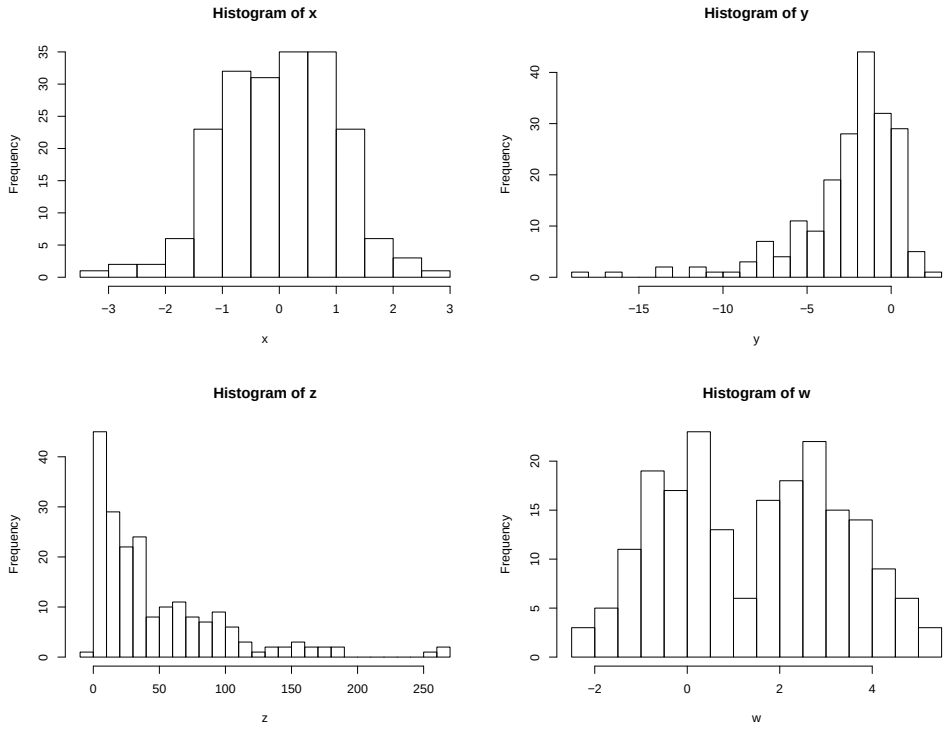
[2] In alcuni libri di testo, si prende come altezza, e non come area, la frequenza relativa dei dati nell'intervallo considerato. In questo caso privilegiamo la definizione con l'area, per due motivi: 1) è più adatta in contesti in cui gli intervalli non hanno la stessa ampiezza; 2) si confronta bene con la densità di probabilità della popolazione, come vedremo.

Per rappresentare un istogramma, è necessario scegliere gli intervalli da usare come basi dei rettangoli. Non tutte le scelte sono buone: nell'esempio precedente (delle altezze di 200 lampadine), scegliere 2 intervalli ci farebbe perdere molta informazione, mentre scegliere 100 intervalli renderebbe l'istogramma troppo dipendente da piccole variazioni dei dati. Esistono alcune regole empiriche sul numero di intervalli da scegliere (generalmente dipendenti dalla numerosità del campione), ma non c'è una regola generale e ogni scelta deve essere confrontata con i dati effettivi a disposizione, ed eventualmente modificata per rendere l'istogramma sufficiente informativo e robusto.

La forma dell'istogramma, o del grafico a barre, viene descritta con una serie di termini relativi a varie caratteristiche:

- "normale" se la forma assomiglia a quella di una campana simmetrica;
- "unimodale" o "bimodale" a seconda che l'istogramma si concentri rispettivamente attorno a una singola o a due colonne più alte;
- nel caso unimodale, asimmetrica (*skewed*) a destra o a sinistra se i dati sono più concentrati a destra o a sinistra del picco;
- "platicurtica" o "leptocurtica" a seconda che, rispettivamente, i dati siano concentrati quasi totalmente in un certo intervallo (anche grande), oppure siano composti da un gruppo centrale e da molti *outliers* (dati isolati distanti dal corpo della distribuzione).

Sono riportati qua sotto 4 istogrammi, rispettivamente normale, asimmetrico a sinistra, a destra, e bimodale. Nella prossima sezione mostriamo come delle quantità matematiche derivate dai dati quantificano questo tipo di descrizione.



1.2 Indici statistici

Supponiamo di avere un vettore $x = (x_1, \ldots, x_n) \in \mathbb{R}^n$ di dati numerici. Gli indici statistici sono quantità numeriche che riassumono alcune proprietà significative della distribuzione dei dati $(x_1, \ldots, x_n)$.

La media campionaria e la mediana campionaria descrivono dove si trova il "centro" della distribuzione dei dati:

Definizione 1.2.1 La **media campionaria** (*sample average*) è la media aritmetica dei dati,

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i.$$

Definizione 1.2.2 La **mediana** (*median*) è il dato x_i tale che metà degli altri valori è minore o uguale a x_i e l'altra metà maggiore o uguale (nel caso n sia pari si può prendere la media aritmetica dei due valori centrali in questo senso).

Nel seguito preferiremo perlopiù la media campionaria alla mediana. Tuttavia la mediana è utile nel caso di dati molto asimmetrici (*skewed*) e soprattutto è robusta rispetto alle code della distribuzione: in altre parole la media campionaria viene facilmente spostata da singoli dati molto piccoli o molto grandi, e questo non succede alla mediana.

La media campionaria si può calcolare a partire dalle frequenze relative dei possibili esiti: se questi ultimi sono $a_1, \dots, a_M$ (ovvero ogni singolo dato x_i è uguale a uno degli a_j),

$$\bar{x} = \sum_{j=1}^{M} a_j p(a_j, x), \quad p(a_j, x) = \frac{\#\{i : x_i = a_j\}}{n},$$

dove appunto $p(a_j, x)$ è la frequenza relativa di a_j nel campione x.

La varianza campionaria si usa per misurare la dispersione dei dati, cioè quanto i dati sono "sparsi" attorno al "centro" della distribuzione. Essa è infatti la media degli scarti quadratici dalla media campionaria $\bar{x}$:

Definizione 1.2.3 La **varianza campionaria** (*sample variance*) oppure la **varianza empirica** (*empirical variance*), rispettivamente

$$\mathrm{var}(x) = \frac{1}{n-1}\sum_{i=1}^{n} (x_i - \bar{x})^2, \quad \mathrm{var}_e(x) = \frac{1}{n}\sum_{i=1}^{n} (x_i - \bar{x})^2.$$

La differenza tra le due quantità suddette è importante in inferenza statistica, e sarà chiara in seguito. Con semplici passaggi si verifica che

$$\sum_{i=1}^{n} (x_i - \bar{x})^2 = \sum_{i=1}^{n} x_i^2 - n\bar{x}^2, \quad \mathrm{var}_e(x) = \sum_{i=1}^{n} \frac{x_i^2}{n} - \bar{x}^2.$$

Inoltre, come per la media campionaria, la varianza empirica (e quindi quella campionaria) può essere espressa in termini delle frequenze relative: detti sempre a_j, $j = 1 \dots M$, i possibili esiti e $p(a_j, x)$ la frequenza relativa di a_j nel campione x, si ha

$$\mathrm{var}_e(x) = \sum_{j=1}^{M} a_j^2 p(a_j, x) - \bar{x}^2.$$

Definizione 1.2.4 La radice della varianza è chiamata scarto quadratico medio o anche deviazione standard (esiste dunque sia campionaria che empirica): la indichiamo $\sigma(x)$ (o $\sigma_e(x)$ quando è empirica) e si ha dunque $\sigma(x) = \sqrt{\mathrm{var}(x)}$.

La varianza, indicata quindi con $\sigma^2(x)$, è evidentemente eguale a 0 se e solo se i dati sono tutti uguali. Più in generale vale:

Proposizione 1.2.1 Preso un campione di dati x ed un numero positivo d si ha

$$\frac{\#(x_i : |x_i - \bar{x}| > d)}{n} \leq \frac{\mathrm{var}_e(x)}{d^2}$$

dove $\#A$ indica il numero degli elementi di A.

Dimostrazione. Si ha che

$$\sum_{i=1}^{n} (x_i - \bar{x})^2 \geq \sum_{i:|x_i-\bar{x}|>d} (x_i - \bar{x})^2 \geq \sum_{i:|x_i-\bar{x}|>d} d^2 = d^2 \cdot \#(x_i : |x_i - \bar{x}| > d),$$

da cui

$$\#(x_i : |x_i - \bar{x}| > d) \leq \frac{\sum_i (x_i - \bar{x})^2}{d^2},$$

e dividendo per n si ha la tesi. ■

Questa formula è un caso particolare della diseguaglianza di Chebyshev che vedremo più avanti, notiamo che il termine di sinistra è la frazione di dati che differiscono da $\bar{x}$ più di d, ed è quindi evidente l'idea di varianza come misura della dispersione dei dati.

■ **Esempio 1.3** Calcoliamo media e varianza campionaria dei dati nell'Esempio 1.1 (10 lanci di un dado) a partire dalle frequenze relative:

$$\bar{x} = \sum_{j=1}^{6} j \cdot p(j,x) = 3.6, \quad \mathrm{var}(x) = \frac{10}{9}\left(\sum_{j=1}^{6} j^2 \cdot p(j,x) - \bar{x}^2\right) \simeq 4.04$$

(le frequenze sono quelle riportate nel grafico a barre). ■

NB Come nel precedente esempio, *indicheremo sempre l'inizio della parte decimale di un numero non intero con il punto* (e non con la virgola), come è uso diffuso nei linguaggi di programmazione al calcolatore.

Se la varianza fa uso della funzione $x \mapsto x^2$ per misurare la distanza media dei punti dalla media campionaria, tramite la funzione $x \mapsto x^3$, che assume valori grandi man mano che x si allontana dall'origine *ma mantenendo il segno di x*, possiamo misurare l'asimmetria della distribuzione. Questo perchè se ci sono molti dati a sinistra della media campionaria, nella somma di termini $(\bar{x} - x_i)^3$ prevarranno quelli con segno negativo, e viceversa.

Definizione 1.2.5 La *sample skewness* (misura campionaria di asimmetria) è

$$b = \frac{1}{\sigma^3} \cdot \frac{1}{n} \sum_{i=1}^{n} (x_i - \bar{x})^3.$$

Senza entrare nei dettagli, menzioniamo che usando la funzione $x \mapsto x^4$ si può misurare in modo simile a sopra "quanto piatta" (o anche "quanto normale") è la distribuzione dei dati, definendo la **curtosi** (*kurtosis*). Nel caso di $x \mapsto x^4$ consideriamo una funzione che resituisce numeri di segno sempre positivo, che crescono molto velocemente all'allontanarsi dall'origine ("pesano le code" della distribuzione). Questa idea chiaramente si può generalizzare ulteriormente per definire varie altre quantità interessanti.

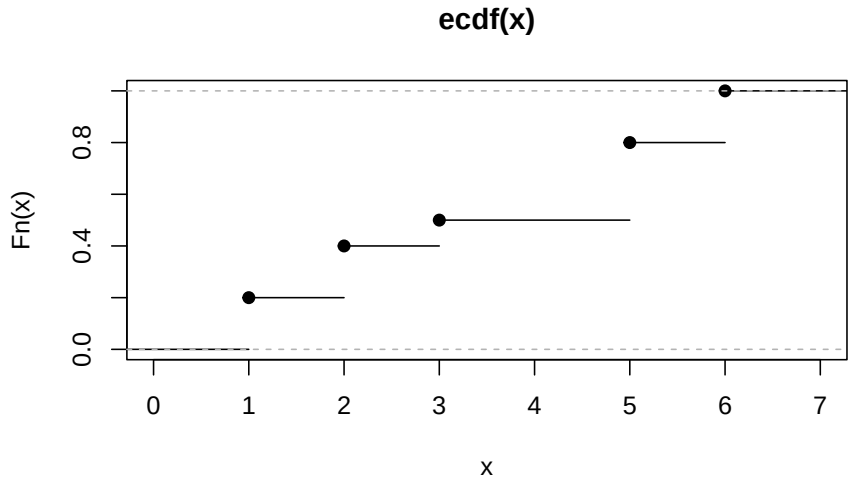


Figura 1.2: Le e.c.d.f. dei dati dell'Esempio 1.1.

1.3 Funzione di ripartizione empirica

Sia $x = (x_1, \dots x_n) \in \mathbb{R}^n$ un vettore di dati numerici. Introduciamo ora uno strumento che risulterà utile nel caratterizzare la distribuzione dei dati: la funzione di ripartizione empirica, indicata anche come e.c.d.f. (*empirical cumulative distribution function*).

Prima di introdurre la definizione formale, vediamo come si ottiene in pratica la e.c.d.f : ordiniamo i numeri $x_1, \dots, x_n$ in ordine crescente chiamandoli $x_{(1)}, \dots, x_{(n)}$ (naturalmente è possibile che due o più siano eguali). La funzione $F_e(t)$ è eguale a 0 per $t < x_{(1)}$, poi fa un salto di ampiezza $1/n$ in corrispondenza di ognuno dei valori $x_{(i)}$ (se due dati sono eguali il salto è di ampiezza $2/n$, se tre dati sono eguali il salto è di ampiezza $3/n$ e così via) e poi è definitivamente eguale a 1 per $t \geq x_{(n)}$.

■ **Esempio 1.4** I seguenti dati sono gli esiti di 36 misurazioni di rumore (in dB, in giorni diversi alla stessa ora) all'esterno della Great Central Station di Manhattan:

82, 89, 94, 110, 74, 122, 112, 95, 100, 78, 65, 60, 90, 83, 87, 75, 114, 85, 69,
94, 124, 115, 107, 88, 97, 74, 72, 68, 83, 91, 90, 102, 77, 125, 108, 65.

La e.c.d.f. corrispondente è riportata nella Figura 1.3 che mostra come, quando i dati sono più numerosi, i "gradini" siano meno accentuati. ■

Vediamo ora la definizione precisa:

Definizione 1.3.1 La funzione di ripartizione empirica $F_e : \mathbb{R} \to \mathbb{R}$ è definita da

$$F_e(t) = \frac{\#(i \mid x_i \leq t)}{n}.$$

In altre parole, per ogni $t \in \mathbb{R}$, $F_e(t)$ restituisce la frequenza relativa dei dati minori o uguali a t. Osserviamo che (banalmente) la funzione F_e è sempre non-decrescente, e $F_e(-\infty) = 0$, $F(+\infty) = 1$.

1.4 Percentili, Quantili e Boxplot

Consideriamo ancora un vettore di dati $x = (x_1, \dots x_n) \in \mathbb{R}^n$. Dato un numero $0 < k < 100$, è naturale chiedersi come scegliere una soglia che divida in due parti i dati, in modo che una di queste

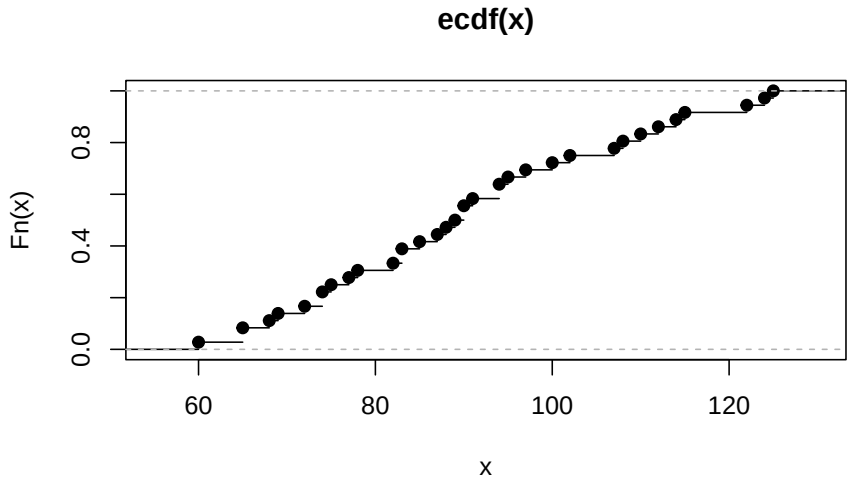


Figura 1.3: e e.c.d.f. dei dati dell'Esempio 1.4.

contenga dati più piccoli di ogni dato dell'altra, e al contempo contenga in totale il $k\%$ dei dati. Ad esempio, se i dati misurano la qualità di un prodotto o l'esito di un test, questa è la procedura con cui si sceglie una porzione predeterminata del campione in modo da selezionare gli esiti migliori, o peggiori.

In effetti, abbiamo già affrontato la questione definendo la mediana: in quel caso $k = 50$, ovvero la mediana divide il campione in due parti con la stessa numerosità. Come in quel caso, definire in generale il k-mo percentile come il più piccolo dato che supera il $k\%$ dei dati non è una buona scelta, perchè (essendo i dati discreti) non sempre uno degli x_i soddisfa esattamente la condizione. Si dà quindi una definizione più elaborata:

Definizione 1.4.1 Si chiama k-mo percentile il dato x_i tale che:
- almeno $\frac{k}{100} \cdot n$ dati siano inferiori o eguali a x_i,
- almeno $\frac{100-k}{100} \cdot n$ siano superiori o eguali a x_i,

e se due o più dati soddisfano questa condizione, si prende come k-mo percentile la media aritmetica tra il più piccolo e il più grande di questi ultimi.

Esercizio 1.1 Si mostri che la seguente definizione è equivalente a quella proposta sopra: il k-mo percentile è il numero t definito da

$$t = \frac{1}{2}\max\{x_i : F_e(x_i) \le k/100\} + \frac{1}{2}\min\{x_i : F_e(x_i) \ge (100-k)/100\}.$$

Si osservi che con i dati dell'Esempio 1.1 (vedi la e.c.d.f. in Figura 1.2), per $k = 50$ il massimo e minimo che appaiono nella formula coincidono, mentre per $k = 60$ no. Qual è il k-mo percentile nei due casi? ■

A livello operativo, il k-mo percentile si calcola in questo modo: detti n la numerosità del campione, $x_{(1)}, \dots x_{(n)}$ i dati ordinati in senso crescente, $\beta = k/100$,

- se βn non è intero, si prende come k-mo percentile $x_{(\lceil \beta n \rceil)}$, dove $\lceil \beta n \rceil$ è l'arrotondamento di βn all'intero successivo;
- se βn è intero, si prende come k-mo percentile la media aritmetica tra $x_{(\beta n)}$ e $x_{(\beta n+1)}$.

In effetti, il parametro $\beta = k/100$ è spesso usato al posto di k, per cui diamo la seguente definizione, che prevarrà quando studieremo le variabili aleatorie.

Definizione 1.4.2 Dato $k \in (0,100)$, e posto $\beta = \frac{k}{100} \in (0,1)$, il k-mo percentile è anche detto β-quantile.

In particolare il 25-mo percentile è chiamato primo quartile, il 50-mo percentile (la mediana) è chiamato secondo quartile, il 75-mo percentile è detto terzo quartile.

Il *box-plot* dei dati è una rappresentazione grafica che evidenzia l'intervallo in cui sono concentrati i dati: si ottiene sovrapponendo a una linea che va dal minimo al massimo dei dati un rettangolo che va dal primo al terzo quartile, con una linea che lo divide al livello della mediana. Qui sotto è riportato un esempio di box-plot. Si noti che il rettangolo centrale contiene il 50% dei dati centrali.

■ **Esempio 1.5** Nell'Esempio 1.4, i 36 dati ordinati sono i seguenti:

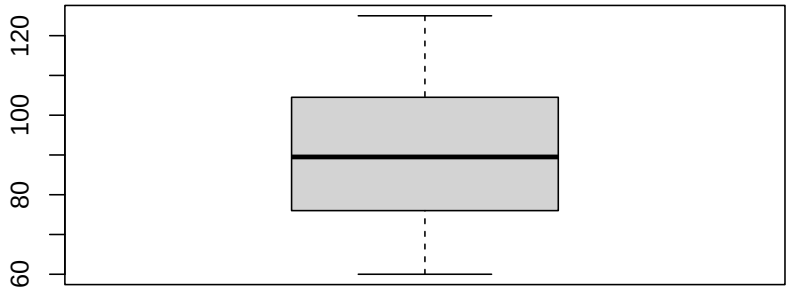
60 65 65 68 69 72 74 74 75 77 78 82 83 83 85 87 88 89

90 90 91 94 94 95 97 100 102 107 108 110 112 114 115 122 124 125

Il primo, secondo e terzo quartile sono quindi:

$$Q_1 = \frac{75+77}{2} = 76, \quad Q_2 = \frac{89+90}{2} = 89.5, \quad Q_3 = \frac{102+107}{2} = 104.5.$$

Il corrispondente boxplot è



■

In statistica si parla di valore anomalo o *outlier* per indicare un valore che differisce in modo significativo dalla "grande maggioranza" dei dati. In alcuni casi si pone il problema di individuare tali valori, per almeno due motivi: gli outliers possono risultare da errori di misurazione, oppure possono indicare code della distribuzione particolarmente pesanti (cioè la distribuzione assume valori estremi con probabilità non troppo bassa). Come osservato nel caso della media campionaria, gli outliers possono influenzare in modo significativo alcuni indici statistici. Non esiste una regola generale per individuare gli outliers, ma un criterio possibile è il seguente: si considerano outlier quelli non compresi nell'intervallo $[Q_1 - 1.5L, Q_3 + 1.5L]$, dove Q_1 e Q_3 sono rispettivamente il primo e il terzo quartile e $L = Q_3 - Q_1$ (detto anche scarto interquantile). In alcune rappresentazioni del boxplot, la linea ha per estremi il più basso e il più alto valore non outlier, mentre gli eventuali dati outlier vengono rappresentati con dei puntini all'esterno di questa linea.

Quando l'istogramma dei dati è (ragionevolmente) normale, vale la seguente regola empirica sulla concentrazione dei dati:

- circa il 68% dei dati appartiene all'intervallo $[\bar{x}-\sigma(x),\bar{x}+\sigma(x)]$;
- circa il 95% dei dati appartiene all'intervallo $[\bar{x}-2\sigma(x),\bar{x}+2\sigma(x)]$;
- circa il 99.7% dei dati appartiene all'intervallo $[\bar{x}-3\sigma(x),\bar{x}+3\sigma(x)]$.

Si tratta appunto di una regola empirica che come tale non può essere dimostrata, ma quando studieremo più avanti le variabili Gaussiane (chiamate anche normali) forniremo una dimostrazione precisa di queste proprietà.

2. Dati Multivariati

Ci limitiamo in questo capitolo al caso di coppie di dati (o dati bivariati): ciò che diremo si adatta facilmente al caso generale. I dati dell'indagine statistica sono in questo caso un insieme di coppie di numeri $(x,y) = ((x_1,y_1),\dots,(x_n,y_n)) \in \mathbb{R}^{2\times n}$. Ad esempio, (x_i,y_i) può essere la misurazione di temperatura e pressione arteriosa per l'i-esimo membro di un campione di pazienti.

2.1 Covarianza e correlazione campionarie

Consideriamo un insieme di n coppie di numeri $(x,y) = ((x_1,y_1),\dots,(x_n,y_n)) \in \mathbb{R}^{2\times n}$. Ricordiamo che $\bar{x}$ e $\bar{y}$ sono le medie campionarie di x e y e $\sigma(x)$, $\sigma(y)$ sono le deviazioni standard campionarie di x e y.

Definizione 2.1.1 Si chiamano covarianza campionaria e covarianza empirica i numeri

$$\mathrm{cov}(x) = \sum_{i=1}^{n} \frac{(x_i-\bar{x})(y_i-\bar{y})}{n-1}, \quad \mathrm{cov}_e(x) = \sum_{i=1}^{n} \frac{(x_i-\bar{x})(y_i-\bar{y})}{n}.$$

Si verifica facilmente che:

$$\sum_{i=1}^{n} (x_i-\bar{x})(y_i-\bar{y}) = \sum_{i=1}^{n} x_i y_i - n\bar{x}\bar{y}, \quad \mathrm{cov}_e(x,y) = \sum_{i=1}^{n} \frac{x_i y_i}{n} - \bar{x}\bar{y}.$$

Definizione 2.1.2 Supponiamo $\sigma(x) \neq 0$ e $\sigma(y) \neq 0$: si chiama coefficiente di correlazione tra x e y il numero

$$r(x,y) = \frac{\mathrm{cov}(x,y)}{\sigma(x)\sigma(y)}.$$

Si può osservare che la definizione non cambia se si sostituiscono covarianza e deviazione standard con covarianza empirica e deviazione standard empirica, ed in realtà vale la formula

$$r(x,y) = \frac{\sum_{i=1}^{n} (x_i-\bar{x})(y_i-\bar{y})}{\sqrt{\sum_{i=1}^{n} (x_i-\bar{x})^2}\sqrt{\sum_{i=1}^{n} (y_i-\bar{y})^2}}.$$

Dalla diseguaglianza di Schwartz in $\mathbb{R}^n$ si deduce

$$\sum_{i=1}^{n} |(x_i - \bar{x}) \cdot (y_i - \bar{y})| \leq \sqrt{\sum_{i=1}^{n} (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^{n} (y_i - \bar{y})^2}$$

e di conseguenza $|r(x,y)| \leq 1$.

2.2 La retta di regressione

Intuitivamente, il coefficiente di correlazione misura il legame di natura lineare tra i dati x e y: introducendo la *retta di regressione* quantifichiamo questa affermazione. L'idea è di approssimare nel modo migliore i dati y_i con una combinazione lineare affine $a + bx_i$, per farlo misuriamo la distanza dei dati da tale retta con i quadrati degli scarti: siamo dunque condotti a cercare i parametri a, b calcolando

$$\inf_{a,b \in \mathbb{R}} \sum_{i=1}^{n} (y_i - a - bx_i)^2 .$$

Questa quantità ha in effetti un unico minimo, e vale il seguente risultato.

Teorema 2.2.1 Supponiamo che $\sigma(x) \neq 0$ e $\sigma(y) \neq 0$. Il minimo al variare di $a, b \in \mathbb{R}$ della quantità $\sum_{i=1}^{n} (y_i - a - bx_i)^2$ si ottiene scegliendo

$$b^* = \frac{\mathrm{cov}(x,y)}{\mathrm{var}(x)}, \quad a^* = -b^* \bar{x} + \bar{y},$$

e vale

$$\min_{a,b \in \mathbb{R}} \sum_{i=1}^{n} (y_i - a - bx_i)^2 = \sum_{i=1}^{n} (y_i - \bar{y})^2 \left(1 - r(x,y)^2\right).$$

La retta $y = a^* + b^* x$ è chiamata retta di regressione: quanto più $r(x,y)$ è vicino a 1 in valore assoluto, tanto più i punti tendono ad essere allineati e vicino a tale retta. In particolare $|r(x,y)| = 1$ se e solo se i punti si trovano tutti su una stessa retta. Inoltre $r(x,y)$ è positivo o negativo se il coefficiente angolare della retta è rispettivamente positivo o negativo. Se $r(x,y)$ è prossimo a zero il Teorema sopra enunciato mostra che non è possibile dare una buona approssimazione dei dati con una retta, nel senso che per ogni retta considerata esisteranno dei dati distanti da essa. Questo non esclude che possano esistere altre relazioni (approssimate) tra x e y, ad esempio quadratiche o più in generale polinomiali.

Dimostrazione. Consideriamo la funzione

$$Q(a,b) = \sum_{i=1}^{n} (y_i - a - bx_i)^2 ,$$

che si osserva facilmente essere continua (in effetti è infinitamente differenziabile). La funzione Q tende a $+\infty$ quando $|a|, |b| \to \infty$ e pertanto ha un minimo. Nel punto di minimo si devono annullare le derivate parziali, ovvero $\frac{\partial Q}{\partial a} = \frac{\partial Q}{\partial b} = 0$, condizione da cui otteniamo il sistema di equazioni

$$\begin{cases} \sum_i y_i - na - b \sum_i x_i = 0, \\ \sum_i x_i y_i - a \sum_i x_i - b \sum_i x_i^2 = 0. \end{cases}$$

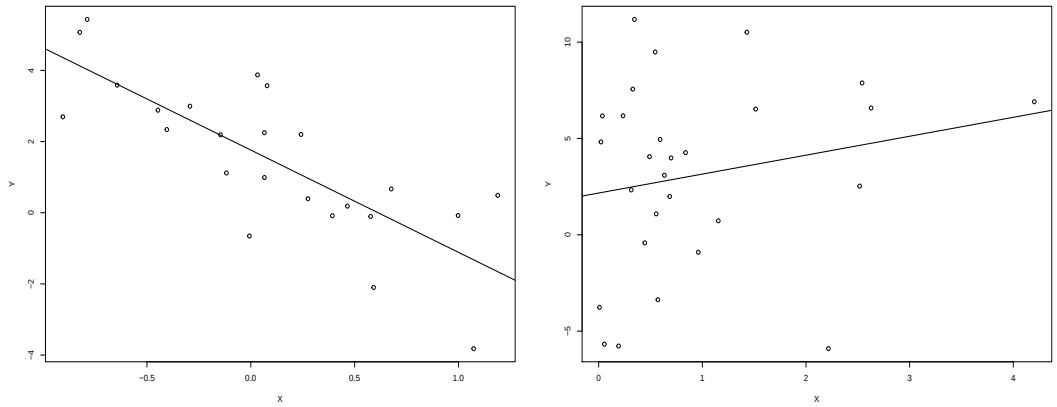


Figura 2.1: Due insiemi di coppie di dati rappresentati come punti sul piano, con relativa retta di regressione. In quello di sinistra, $r(x,y) \approx -0.78, a^* \approx 1.76$ e $b^* \approx -2.87$, mentre in quello di destra i dati sono molto più sparpagliati e il coefficiente di correlazione è ≈ 0.2422.

Dividendo per n si ottiene

$$\begin{cases} a + b\bar{x} = \bar{y}, \\ a\bar{x} + b\sum_i \frac{x_i^2}{n} = \sum_i \frac{x_i y_i}{n}, \end{cases}$$

che è un sistema di due equazioni nelle due incognite a, b. L'unica soluzione è

$$a^* = -b^*\bar{x} + \bar{y}, \quad b^* = \frac{\sum_i \frac{x_i y_i}{n} - \bar{x}\bar{y}}{\sum_i \frac{x_i^2}{n} - \bar{x}^2} = \frac{\mathrm{cov}_e(x,y)}{\mathrm{var}_e(x)}.$$

Essendo l'unico punto stazionario di Q questo coincide con il suo minimo, che quindi è unico. Il valore di Q nel minimo, $Q(a^*, b^*) = \sum_{i=1}^n (y_i - \bar{y})^2 \left(1 - r(x,y)^2\right)$, si ottiene sostituendo i valori trovati e sviluppando i calcoli. ■

II Probabilità

3 Probabilità e (In)dipendenza 23
3.1 Spazi di Probabilità
3.2 Calcolo Combinatorio
3.3 Probabilità Condizionata e formula di Bayes
3.4 Indipendenza
3.5 Probabilità sulla retta reale
3.6 Esercizi

3. Probabilità e (In)dipendenza

Non possiamo conoscere con certezza il futuro, ovvero ogni affermazione che possiamo fare su eventi futuri può realizzarsi o meno. La teoria della Probabilità nasce per tentare di quantificare questa incertezza, misurando in qualche modo la fiducia che un evento possa accadere. I primi due obbiettivi della Probabilità in quanto parte della Matematica sono: rappresentare con oggetti matematici gli eventi in analisi e la loro probabilità; determinare le proprietà che questi oggetti soddisfano mostrando da un lato che costituiscono un modello della realtà, e dall'altro che di questa possono fornire informazioni ulteriori rispetto a quelle osservate.

La definizione matematica di probabilità è stata data negli anni '30 del Novecento con le opere di Kolmogorov ed è di tipo assiomatico, cioè definisce la probabilità in modo rigoroso tramite le sue proprietà elementari. Storicamente, tale definizione fu preceduta da altre non rigorose, rifacentesi piuttosto a interpretazioni del concetto di probabilità, e che possono essere utili per collegare il fenomeno aleatorio reale con un modello probabilistico associato. Ne menzioniamo brevemente due: la definizione classica e quella frequentista, tralasciandone altre comunque importanti come la definizione soggettivista.

La definizione classica considera la probabilità come rapporto tra numero di casi favorevoli e numero di casi possibili (si veda il *modello uniforme* nel seguito). Questa interpretazione è adatta a descrivere problemi come le estrazioni da una popolazione ed è conveniente sia per alcuni calcoli elementari (riconducendosi essenzialmente a contare gli elementi di un insieme) sia per l'intuizione probabilistica (se la probabilità di un evento A è $1/4$, possiamo immaginare una popolazione di casi equiprobabili in cui A si realizzi in un quarto dei casi). È meno adatta, a descrivere fenomeni in cui la popolazione è ideale, e possibilmente infinita, come l'esecuzione di un esperimento fisico (affetto da errore) o l'effetto della somministrazione di un farmaco (affetto dalla variabilità dei soggetti cui è somministrato).

La definizione frequentista considera la probabilità di un evento come il limite, per $n \to \infty$, delle frequenze relative dell'evento in n prove ripetute dell'esperimento. Questa interpretazione descrive meglio fenomeni con popolazione ideale, come appunto l'esecuzione di un esperimento fisico. Richiede però di conoscere a priori che il limite esista (e la definizione rigrosa del limite non è chiara). Al fine dell'intuizione, può essere utile osservare che, idealmente, la definizione

frequentista è il limite della definizione classica per grande numero di prove.

3.1 Spazi di Probabilità

Consideriamo un certo esperimento aleatorio, cioè un fenomeno (fisico, biologico, sociale, ...) il cui esito non è determinabile con certezza a priori. La costruzione delle probabilità come oggetto matematico inizia da una semplice osservazione: possiamo rappresentare tutti gli esiti possibili dell' esperimento con gli elementi di un insieme astratto Ω, detto *spazio campionario* (*sample space*). I sottoinsiemi di Ω, che *definiremo* eventi, rappresentano affermazioni che possiamo fare sull'esito dell'esperimento. Di conseguenza, combinazioni di affermazioni diverse ottenute tramite i connettivi logici ("o", "e", "non", "implica") corrispondono come è noto ad operazioni insiemistiche. I singoli esiti, cioè gli elementi di Ω, sono detti eventi elementari (con abuso di notazione, parliamo di eventi elementari per intendere sia gli elementi ω in Ω, sia gli insiemi singoletto $\{\omega\}$).

■ **Esempio 3.1** Per rappresentare il risultato del lancio di un dado a sei facce l'insieme degli esiti è $\Omega = \{1,2,3,4,5,6\}$. Le affermazioni "è uscito un numero pari" oppure "è uscito un numero maggiore di 3" si traducono con i sottinsiemi $A = \{2,4,6\}$ e $B = \{4,5,6\}$; l'affermazione "non maggiore di 3" diventa $B^c = \{1,2,3\}$, l'affermazione "pari e maggiore di 3" diventa $A \cap B = \{4,6\}$. Allo stesso modo "pari oppure maggiore di 3 " diventa $A \cup B$. L'intero spazio Ω diventa l'evento che sicuramente si è realizzato, "è uscito un numero intero tra 1 e 6", l'insieme vuoto $\emptyset$ rappresenta un evento impossibile, come "è uscito 7". ■

Esercizio 3.1 Verificare le seguenti corrispondenze tra operazioni logiche e operazioni insiemistiche:

$$\begin{aligned} \cap_i A_i &\leftrightarrow \text{ si verificano tutti gli } A_i, \\ \cup_i A_i &\leftrightarrow \text{ si verifica almeno un } A_i, \\ A^c = \Omega \setminus A &\leftrightarrow \text{ non si verifica } A, \\ A \setminus B &\leftrightarrow \text{ si verifica } A \text{ ma non } B, \\ A \Delta B := (A \setminus B) \cup (B \setminus A) &\leftrightarrow \text{ si verifica o } A \text{ o } B. \end{aligned}$$

Verificare inoltre la seguente corrispondenza tra relazioni logiche e relazioni insiemistiche:

$$\begin{aligned} A \subseteq B &\leftrightarrow \text{ se accade } A, \text{ allora accade } B, \\ A \cap B = \emptyset &\leftrightarrow \text{ non possono accadere sia } A \text{ sia } B \text{ (eventi incompatibili).} \end{aligned}$$

■

Alla luce di queste considerazioni, risulta chiara la necessità di operare con famiglie di eventi chiuse per le operazioni insiemistiche sopra menzionate, ovvero tali che le operazioni insiemistiche tra eventi producano ancora degli eventi. Questo è banale se la famiglia di eventi che consideriamo consiste di *tutti* i sottoinsiemi di Ω, $\mathscr{P}(\Omega)$, ma in generale questo non è possibile (fatto su cui torniamo più sotto). Siamo stati dunque condotti a dare la seguente definizione:

Definizione 3.1.1 Sia Ω un insieme e $\mathscr{F} \subseteq \mathscr{P}(\Omega)$ una famiglia di sottoinsiemi di Ω. Diciamo che $\mathscr{F}$ è un'*algebra di parti* se

- contiene l'insieme vuoto $\emptyset$ e Ω, $\emptyset, \Omega \in \mathscr{F}$;
- è chiusa per complementari, ovvero se $A \in \mathscr{F}$ anche $A^c = \Omega \setminus A \in \mathscr{F}$;
- è chiusa per unioni (finite), ovvero se $A_1, \ldots, A_n \in \mathscr{F}$ anche $A_1 \cup \cdots \cup A_n \in \mathscr{F}$.

Se inoltre Ω e una sua algebra di parti $\mathscr{F}$ hanno infiniti elementi, diciamo che $\mathscr{F}$ è una σ-*algebra*

se soddisfa l'ipotesi addizionale:

- è chiusa per unioni numerabili, ovvero se esiste una successione di sottoinsiemi (eventi) $A_1,\dots,A_n,\dots \in \mathscr{F}$ anche la loro unione $\cup_{n=1}^{\infty} A_n \in \mathscr{F}$.

Esercizio 3.2 Usando le leggi di de Morgan, $(A\cup B)^c = A^c \cap B^c$, $(A\cap B)^c = A^c \cup B^c$, si mostri che un'algebra di parti è anche chiusa per intersezioni finite, ovvero se $A_1,\dots,A_n \in \mathscr{F}$ anche $A_1 \cap \dots \cap A_n \in \mathscr{F}$. Nel caso di una σ-algebra, si mostri che essa è chiusa per intersezioni numerabili. ■

La definizione di σ-algebra permette di eseguire tutte le operazioni insiemistiche che ci servono anche nel caso in cui Ω sia infinito, come accadrà diffusamente nel seguito.

■ **Esempio 3.2** Se vogliamo descrivere le nascite del prossimo anno in Italia dovremo considerare $\Omega = \mathbb{N}_0 = \{1,2,\dots\}$, perchè sebbene l'esito sia certamente finito esso può assumere valori arbitrariamente grandi, anche se più grande è l'esito considerato, meno esso sarà probabile. ■

■ **Esempio 3.3** Lo spazio campionario Ω associato a due lanci (ordinati) di un dado è dato da

$$\{(i,j) \mid i,j \in \{1,2,\dots 6\}\} = \{1,2,\dots 6\}^2,$$

ovvero dall'insieme di tutte le coppie di possibili esiti. ■

Più in generale, se un esperimento è costituito da una successione (ordinata) di n sotto-esperimenti, allora il suo spazio campionario è

$$\Omega = \{(\omega_1,\omega_2,\dots \omega_n) \mid \omega_1 \in \Omega_1,\dots \omega_n \in \Omega_n\}$$

dove Ω_i è l'insieme degli esiti dell'i-simo sotto-esperimento.

Esercizio 3.3 In 3 lanci di dado, a quali insiemi corrispondono gli eventi "esce un numero pari al primo lancio" ed "esce 3 al primo lancio e un numero pari al terzo lancio"? ■

Il grado di fiducia che un evento si realizzi, chiamato probabilità, è rappresentato da un numero compreso tra 0 e 1; inoltre è intuitivo supporre che se due eventi sono incompatibili (ovvero sono disgiunti, hanno intersezione vuota) la probabilità che si realizzi uno qualsiasi dei due debba essere la somma delle probabilità dei singoli eventi. Questo equivale a dire che la probabilità è una funzione d'insieme (finitamente) additiva. Come sopra, la definizione generale deve tenere debitamente conto del caso in cui dobbiamo trattare infiniti eventi.

Definizione 3.1.2 Dato Ω un insieme e $\mathscr{F}$ una σ-algebra di parti di Ω, una *misura di probabilità* (*probability measure*, anche semplicemente "una probabilità") è una funzione $\mathbb{P} : \mathscr{F} \to [0,1]$ tale che

- l'evento certo ha probabilità unitaria, $\mathbb{P}(\Omega) = 1$;
- (σ-additività) se $(A_n)_{n=1,2,\dots}$ è una successione di elementi di $\mathscr{F}$ a due a due disgiunti, si ha

$$\mathbb{P}\left(\bigcup_{n=1}^{+\infty} A_n\right) = \sum_{n=1}^{+\infty} \mathbb{P}(A_n).$$

Si dice *trascurabile* (*negligible*) un evento A tale che $\mathbb{P}(A) = 0$, e si dice *quasi certo* (*almost sure*) un evento A tale che $\mathbb{P}(A) = 1$.

Una terna $(\Omega, \mathscr{F}, \mathbb{P})$ formata da un insieme Ω, una σ-algebra $\mathscr{F}$ di parti di Ω ed una probabilità $\mathbb{P}$ definita su $\mathscr{F}$ viene chiamata spazio di Probabilità.

Naturalmente la σ-additività implica l'additività su finiti sottoinsiemi disgiunti, cioè, dati $A_1, \dots A_N$ elementi di $\mathscr{F}$ a due a due disgiunti,

$$\mathbb{P}\left(\bigcup_{n=1}^{N} A_n\right) = \sum_{n=1}^{N} \mathbb{P}(A_n);$$

infatti, è sufficiente scegliere $A_n = \emptyset$ da un certo n in poi per specializzare la definizione generale al caso finito.

Ogni misura di probabilità verifica le segueni proprietà, la cui dimostrazione è lasciata per esercizio:

Proposizione 3.1.1 In uno spazio di probabilità $(\Omega, \mathscr{F}, \mathbb{P})$, abbiamo:

- $\mathbb{P}(A^c) = 1 - \mathbb{P}(A)$ e di conseguenza $\mathbb{P}(\emptyset) = 0$;
- se $B \subset A$, $\mathbb{P}(A \setminus B) = \mathbb{P}(A) - \mathbb{P}(B)$, dove ricordiamo che la differenza insiemistica corrisponde a $A \setminus B = A \cap B^c$;
- $\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B)$;
- $\mathbb{P}(A \cup B \cup C) = \mathbb{P}(A) + \mathbb{P}(B) + \mathbb{P}(C) - \mathbb{P}(A \cap B) - \mathbb{P}(A \cap C) - \mathbb{P}(B \cap C) + \mathbb{P}(A \cap B \cap C)$.

Esercizio 3.4 Dimostrare questa proposizione. Come si estendono le ultime due formule nel caso di 4 o più eventi? ■

La σ-additività permette di "passare al limite", nel senso reso preciso dal seguente risultato

Proposizione 3.1.2 Data una successione di insiemi $A_1, \dots, A_n, \dots \in \mathscr{F}$, assumiamo (alternativamente) che

- la successione sia crescente, ovvero $A_n \subseteq A_{n+1}$, e poniamo $A = \bigcup_{n=1}^{+\infty} A_n = \lim_{n\to\infty} A_n$;
- la successione sia decrescente, ovvero $A_n \supseteq A_{n+1}$, e poniamo $A = \bigcap_{n=1}^{+\infty} A_n = \lim_{n\to\infty} A_n$.

In entrambi i casi vale

$$\mathbb{P}(A) = \lim_{n\to\infty} \mathbb{P}(A_n).$$

Dimostrazione. Consideriamo dapprima il caso in cui la successione è crescente. Poniamo $B_1 = A_1, B_n = A_n \setminus A_{n-1}$ per $n > 1$. Gli insiemi $(B_n)_{n\geq 1}$ sono a due a due disgiunti e per l'additività finita si ha $\mathbb{P}(B_n) = \mathbb{P}(A_n) - \mathbb{P}(A_{n-1})$. Poiché $\bigcup_{n\geq 1} A_n = \bigcup_{n\geq 1} B_n$, si ha $\mathbb{P}(A) = \sum_{n=1}^{+\infty} \mathbb{P}(B_n) = = \lim_{n\to\infty} \sum_{h=1}^{n} \mathbb{P}(B_h) = \lim_{n\to\infty} \mathbb{P}(A_n)$.

Nel caso in cui la successione è decrescente la tesi segue dal caso crescente semplicemente passando al complementare. ■

In effetti si può dimostrare che se una funzione $\mathbb{P} : \mathscr{F} \to [0,1]$ definita su una σ-algebra è finitamente additiva (vale l'additività su famiglie finite di eventi) ed inoltre soddisfa la tesi della Proposizione precedente, allora è anche σ-additiva.

Prima di procedere oltre, torniamo sulla questione del perché in alcune situazioni la probabilità è assegnata solo su alcuni e non tutti i sottinsiemi dello spazio Ω, ovvero perchè abbiamo ammesso che $\mathscr{F}$ non coincida con $\mathscr{P}(\Omega)$, l'insieme delle parti di Ω (che *è sempre* una σ-algebra). Il motivo di questo è una difficoltà esclusivamente di ordine matematico, ovvero l'impossibilità, in alcuni casi, di estendere la probabilità a tutti i sottinsiemi dell'insieme Ω.

■ **Esempio 3.4** Cerchiamo di rappresentare la scelta casuale di un punto del segmento $[0,1]$, in modo che tale scelta sia "uniforme", ovvero che tutti i punti abbiano la stessa probabilità di essere scelti (su questi concetti torneremo diffusamente in seguito). Scegliamo dunque $\Omega = [0,1]$. Se ogni punto avesse la stessa probabilità non nulla, la probabilità dell'intero Ω sarebbe infinita, quindi non possiamo costruire così il nostro modello. Invece, è ragionevole assegnare a un evento (sottoinsieme) $A \subset \Omega = [0,1]$ una probabilità uguale alla sua lunghezza: in effetti così facendo la

probabilità di tutto Ω è 1, e dovrebbero essere soddisfatte anche le altre richieste che facciamo alla funzione $\mathbb{P}$. Tuttavia, si può dimostrare (ed è una questione alquanto delicata) che *non è possibile definire la lunghezza di un qualsiasi sottoinsieme del segmento*, quindi in questo caso la σ-algebra *non può essere* $\mathscr{P}(\Omega)$, e la sua scelta non è banale. ∎

Questo problema non si pone se Ω è numerabile, ovvero se si possono indicizzare i suoi elementi con (un sottoinsieme possibilmente finito de)i numeri naturali $\mathbb{N}$,

$$\Omega = (\omega_1, \omega_2, \dots, \omega_n, \dots).$$

In tal caso la probabilità è univocamente determinata dai numeri

$$p_i = \mathbb{P}(\omega_i) = \mathbb{P}(\{\omega_i\}) \in [0,1]$$

(ometteremo d'ora in avanti le doppie parentesi nelle probabilità di insiemi con un singolo elemento) e per ogni evento $A \subset \Omega$ si ha $\mathbb{P}(A) = \sum_{\omega_i \in A} p_i$. Il simbolo di somma qui indica una somma finita se A ha finiti elementi (ovvero sempre nel caso in cui Ω stesso sia finito), e la somma di una serie[1] se A ha infiniti elementi.

3.2 Calcolo Combinatorio

Un esempio significativo di spazio di probabilità è il modello uniforme:

Definizione 3.2.1 Una distribuzione di probabilità $\mathbb{P}$ si dice uniforme su Ω se Ω è un insieme finito, $\mathscr{F} = \mathscr{P}(\Omega)$ e gli eventi elementari ω_i sono equiprobabili.

Ne sono esempi i modelli associati all'estrazione da un'urna e al lancio di un dado equilibrato. Come accennato sopra, non esiste una distribuzione uniforme di probabilità su un insieme Ω numerabile ma infinito.

Per una probabilità uniforme $\mathbb{P}$ su uno spazio finito Ω, si ottiene la formula

$$\mathbb{P}(A) = \frac{\#A}{\#\Omega} = \frac{\text{"casi favorevoli"}}{\text{"casi possibili"}}, \quad A \subseteq \Omega,$$

dove con $\#A$ si indica la cardinalità (o numero degli elementi) dell'insieme A.

In questo ambito, i problemi diventano molto spesso calcoli combinatori: riportiamo qui (ed useremo nel seguito) solamente tre formule notevoli. Dato un intero n, anziché dire "un insieme di n elementi", scriveremo per brevità $\{1,\dots,n\}$.

Proposizione 3.2.1 Siano k ed n due interi.

- il numero di sequenze ordinate, possibilmente con ripetizione, di k numeri da 1 a n, cioè il numero di funzioni da $\{1,\dots,k\}$ a $\{1,\dots,n\}$ è n^k;
- il numero di modi in cui si possono ordinare gli elementi di $\{1,\dots,n\}$ (ovvero il numero di funzioni biiettive dall'insieme a se stesso, o di permutazioni di n elementi) è

$$n! = 1 \cdot 2 \cdots (n-1) \cdot n;$$

- se $0 \le k \le n$, il numero di sottinsiemi di $\{1,\dots,n\}$ formati da k elementi (coefficiente binomiale) è

$$\binom{n}{k} = \frac{n!}{k!(n-k)!} = \frac{n \cdot (n-1) \dots (n-k+1)}{k!},$$

[1] Si può dimostrare che non esistono serie convergenti di termini non-negativi con una quantità più che numerabile di addendi, da cui l'impossibilità di estendere queste affermazioni al caso in cui Ω è più che numerabile.

dove $n! = n \cdot (n-1) \cdot \ldots 2 \cdot 1$ per $n \in \mathbb{N}_0$ e $0! = 1$.

Questi enunciati si dimostrano facilmente per induzione su n. Il coefficiente binomiale è così detto perché interviene nella formula del binomio di Newton:

$$(a+b)^n = \sum_{k=0}^{n} \binom{n}{k} a^k b^{n-k}, \quad a,b \in \mathbb{R}, n \in \mathbb{N}.$$

A titolo d'esempio, e lasciando la dimostrazione per esercizio, riportiamo due formule che si possono dedurre dalle precedenti.

Esercizio 3.5 Siano $0 \leq k \leq n$: il numero di sequenze ordinate senza ripetizione di k numeri di $\{1,\ldots,n\}$ è $\frac{n!}{(n-k)!}$. Si noti che questo numero coincide anche con il numero delle applicazioni iniettive da $\{1,\ldots,k\}$ in $\{1,\ldots,n\}$. ■

Esercizio 3.6 Siano $k_1,\ldots,k_h$ interi con $k_1 + \cdots + k_h = n$: il numero di modi in cui si possono scegliere h sottinsiemi di $\{1,\ldots,n\}$ formati rispettivamente da $k_1,\ldots,k_h$ elementi è

$$\binom{n}{k_1,\ldots,k_h} = \frac{n!}{k_1!\ldots k_h!}.$$

■

■ **Esempio 3.5** Consideriamo l'esperimento dato da k estrazioni ordinate, con rimpiazzo, da una popolazione S di n oggetti, ad esempio un'urna di n biglie (per rimpiazzo si intende che l'oggetto estratto viene nuovamente inserito nell'urna e quindi può essere selezionato nelle estrazioni successive). Questo esperimento è descritto dallo spazio di probabilità $(\Omega, \mathscr{P}(\Omega), \mathbb{P})$ con $\Omega = S^n$ e $\mathbb{P}$ uniforme: infatti tutte le possibili sequenze di k oggetti estratti sono equiprobabili. In particolare $P(A) = \#A/\#\Omega$ con $\#\Omega = n^k$.

Lo stesso modello si può usare per k lanci di un dado equilibrato (qui $S = \{1,2,\ldots 6\}$) e k lanci di moneta equilibrata (qui $S = \{\text{testa}, \text{croce}\}$). ■

■ **Esempio 3.6** Consideriamo l'esperimento dato da k estrazioni ordinate, questa volta senza rimpiazzo, da una popolazione S di n oggetti, con $k \leq n$. Anche in questo caso il modello è uniforme, ma con un diverso spazio campionario: $\Omega = \{(x_1,\ldots x_k) \mid x_i \in S, x_i \text{ tutti distinti}\}$, con $\#\Omega = n!/(n-k)!$. ■

Esercizio 3.7 Consideriamo ora l'estrazione senza ordine e senza rimpiazzo di 2 oggetti da un'urna di 10 oggetti (che indichiamo con $\{1,2,\ldots 10\}$); qui "senza ordine" indica che ignoriamo l'ordine di estrazione, quindi ad esempio consideriamo uguali gli esiti $(3,7)$ e $(7,3)$. Scrivere lo spazio campionario corrispondente e la sua cardinalità; la misura di probabilità è uniforme?

Se si considera l'estrazione senza ordine ma con rimpiazzo? ■

3.3 Probabilità Condizionata e formula di Bayes

Quando si è a conoscenza della realizzazione di un evento, cambia la valutazione di probabilità di ogni altro evento: ad esempio se si sa che il numero uscito dal lancio di un dado è pari, la probabilità che sia uscito il numero 6 non è più $\frac{1}{6}$, ma $\frac{1}{3}$. Infatti, se si è realizzato l'evento $B = \{2,4,6\}$ (cioè è uscito un numero pari) sono rimasti 3 casi possibili dei quali uno è favorevole: se indichiamo con $A = \{6\}$, notiamo che la nuova probabilità che è stata attribuita ad A verifica la formula $\frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}$.

Si possono fornire diversi esempi simili che sempre verificano la formula sopra riportata: queste considerazioni sono all'origine della definizione che segue.

Definizione 3.3.1 Assegnato uno spazio di probabilità $(\Omega, \mathscr{F}, \mathbb{P})$ ed un evento B non trascurabile, si chiama probabilità condizionata di A rispetto a B il numero

$$\mathbb{P}(A \mid B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}.$$

Essa indica la probabilità che viene associata all'evento A, coerentemente con la valutazione precedentemente assegnata, in seguito all'informazione che si è realizzato l'evento B. È facile verificare che, fissato B non trascurabile, la funzione

$$A \mapsto \mathbb{P}(A \mid B)$$

è effettivamente una probabilità.

Esercizio 3.8 Verificare con un esempio che la funzione $B \mapsto \mathbb{P}(A \mid B)$ *non* è una probabilità. ■

Dati due eventi A e B non trascurabili, è immediato constatare che

$$\mathbb{P}(A \cap B) = \mathbb{P}(A \mid B) \cdot \mathbb{P}(B) = \mathbb{P}(B \mid A) \cdot \mathbb{P}(A).$$

Più in generale vale la seguente:

Proposizione 3.3.1 — Condizionamento ripetuto. Siano $A_1, \ldots, A_n$ eventi, e supponiamo che $A_1 \cap \ldots \cap A_{n-1}$ sia non trascurabile: vale la formula

$$\mathbb{P}(A_1 \cap \ldots \cap A_n) = \mathbb{P}(A_1) \cdot \mathbb{P}(A_2 \mid A_1) \ldots \mathbb{P}(A_n \mid A_1 \cap \ldots \cap A_{n-1}).$$

La dimostrazione si ottiene (per induzione) esplicitando i vari termini; si noti che, se $1 \leq k < n-1$, anche $A_1 \cap \ldots \cap A_k$ è non trascurabile.

Definizione 3.3.2 Una partizione di Ω è una collezione di n eventi $B_1, \ldots, B_n$ a due a due disgiunti, tali che $B_1 \cup \cdots \cup B_n = \Omega$. Un sistema di alternative è una partizione di Ω in eventi non trascurabili.

Teorema 3.3.2 — Formula della probabilità totale o formula di fattorizzazione. Sia $B_1, \ldots, B_n$ un sistema di alternative. Allora, per un qualunque evento A, vale

$$\mathbb{P}(A) = \sum_{i=1}^{n} \mathbb{P}(A \mid B_i)\, \mathbb{P}(B_i).$$

Dimostrazione. Si noti che $A = (A \cap B_1) \cup \ldots \cup (A \cap B_n)$, come unione di eventi a due a due disgiunti. Si ha pertanto

$$\mathbb{P}(A) = \sum_{i=1}^{n} \mathbb{P}(A \cap B_i) = \sum_{i=1}^{n} \mathbb{P}(A \mid B_i)\, \mathbb{P}(B_i).$$

■

La formula della probabilità totale si usa in esempi in cui non è nota la probabilità $\mathbb{P}$ ma sono note le probabilità condizionate a un sistema di alternative, cioè $\mathbb{P}(\cdot \mid B_i)$, come si vede da queste due classiche applicazioni:

■ **Esempio 3.7** Siano u_1 e u_2 due urne, la prima contenente 5 biglie rosse e 5 blu, la seconda 8 biglie rosse e 2 blu. L'esperimento in esame consiste nello scegliere casualmente una delle due

urne e poi nell'estrarre una biglia dall'urna scelta e osservarne il colore. Vogliamo calcolare la probabilità di estrarre una biglia rossa. Lo spazio campionario è dato da

$$\Omega = \{(x,y) \mid x \in \{u_1,u_2\}, y \in \{r,b\}\} = \{u_1,u_2\} \times \{r,b\}$$

(dove r,b stanno per "rosso" e "blu")[2]. Sulla probabilità sappiamo che la scelta dell'urna è equiprobabile, cioè

$$\mathbb{P}(\text{urna } 1) = \mathbb{P}(\text{urna } 2) = 1/2,$$

e che, data la scelta dell'urna 1, rispettivamente dell'urna 2, la probabilità di una biglia rossa è $5/10$, rispettivamente $8/10$, cioè

$$\mathbb{P}(\text{biglia rossa} \mid \text{urna } 1) = 5/10,$$
$$\mathbb{P}(\text{biglia rossa} \mid \text{urna } 2) = 8/10.$$

Grazie alla formula della probabilità totale abbiamo

$$\mathbb{P}(\text{biglia rossa}) = \mathbb{P}(\text{biglia rossa} \mid \text{urna } 1)\mathbb{P}(\text{urna } 1) + \mathbb{P}(\text{biglia rossa} \mid \text{urna } 2)\mathbb{P}(\text{urna } 2) = 13/20.$$

■

Esercizio 3.9 Un test diagnostico per una data malattia ha indice di sensibilità 0.99, cioè, se una persona è malata, il test dà esito positivo con probabilità 0.99; inoltre il test ha indice di specificità 0.97, cioè, se una persona è sana, il test dà esito negativo con probabilità 0.97. Supponiamo che l'1% della popolazione soffra di tale malattia. Qual è la probabilità che il test, effettuato su un individuo scelto a caso, dia esito positivo? ■

Teorema 3.3.3 — Formula di Bayes. Siano A e B due eventi non trascurabili. Allora vale la formula

$$\mathbb{P}(B \mid A) = \frac{\mathbb{P}(A \mid B)\mathbb{P}(B)}{\mathbb{P}(A)}$$

Come conseguenza, se $B_1,\dots,B_n$ è un sistema di alternative e A è un evento non trascurabile, vale

$$\mathbb{P}(B_i \mid A) = \frac{\mathbb{P}(A \mid B_i)\,\mathbb{P}(B_i)}{\mathbb{P}(A)} = \frac{\mathbb{P}(A \mid B_i)\,\mathbb{P}(B_i)}{\sum_{j=1}^{n} \mathbb{P}(A \mid B_j)\,\mathbb{P}(B_j)}.$$

Dimostrazione. La prima formula segue dalla definizione di probabilità condizionata:

$$\mathbb{P}(B \mid A) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(A)} = \frac{\mathbb{P}(A \mid B)\mathbb{P}(B)}{\mathbb{P}(A)}.$$

La seconda formula segue dalla prima e dalla formula della probabilità totale. ■

La formula di Bayes si applica per "invertire il condizionamento", tipicamente in contesti in cui accade un evento A riferito a un'"osservabile" (negli esempi che seguono, colore della biglia, esito del test) e vogliamo dedurre la probabilità di un'alternativa B_i di eventi "causa" (urna scelta, persona sana o malata).

[2] Nel seguito, chiamiamo l'evento "viene scelta l'urna 1", cioè $\{u_1\} \times \{r,b\}$ (da non confondersi con u_1), e anche "biglia rossa" l'evento "viene estratta una biglia rossa", cioè $\{u_1,u_2\} \times \{r\}$ (da non confondersi con r), e così via.

■ **Esempio 3.8** Nel contesto dell'Esempio 3.7, supponiamo di estrarre una biglia rossa, vogliamo calcolare la probabilità che la biglia provenga dall'urna 1. Per il teorema di Bayes abbiamo

$$\mathbb{P}(\text{urna 1} \mid \text{biglia rossa}) = \frac{\mathbb{P}(\text{biglia rossa} \mid \text{urna 1})\mathbb{P}(\text{urna 1})}{\mathbb{P}(\text{biglia rossa})} = \frac{5/10 \cdot 1/2}{13/20} \approx 0.385.$$

■

Esercizio 3.10 Nel contesto dell'Esercizio 3.9, supponiamo che il test dia risultato positivo. Qual è la probabilità che la persona sia effettivamente malata? piuttosto bassa! ■

La formula della probabilità totale e il teorema di Bayes sono valide anche se il sistema di alternative anziché essere finito è numerabile, naturalmente sostituendo alle somme finite le somme di una serie.

Esercizio 3.11 Qual è la probabilità che, in una estrazione del lotto, tutti e 5 i numeri estratti siano inferiori o eguali a 20 ? (Lo si calcoli dapprima con un ragionamento combinatorio, e quindi con la formula di Bayes). ■

3.4 Indipendenza

Vogliamo codificare nel formalismo matematico l'idea che la conoscenza che si è realizzato un certo evento non modifica la valutazione di probabilità di un altro evento, e viceversa. Consideriamo quindi due eventi A e B (non trascurabili) e imponiamo che

$$\mathbb{P}(A) = \mathbb{P}(A \mid B), \qquad \mathbb{P}(B) = \mathbb{P}(B \mid A).$$

Un esame immediato mostra che queste richieste sono equivalenti tra loro, ed equivalenti all'eguaglianza $\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B)$. A differenza delle due precedenti, quest'ultima è simmetrica rispetto ai due eventi ed ha senso anche se uno dei due (o anche tutti e due) sono trascurabili: viene scelta dunque come definizione di indipendenza.

Definizione 3.4.1 Due eventi A e B sono indipendenti se vale

$$\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B).$$

Lasciamo come (facile) esercizio le seguenti proprietà:

Esercizio 3.12
- Se A e B sono indipendenti, lo sono anche A^c e B, A e B^c, A^c e B^c;
- se $\mathbb{P}(A) = 0$ oppure $\mathbb{P}(A) = 1$, A è indipendente da qualsiasi altro evento;
- due eventi disgiunti non possono essere indipendenti, a meno che almeno uno dei due sia trascurabile.

■

Esercizio 3.13 Un mazzo di carte Italiane è composto da 40 carte, divise in 4 semi –bastoni, coppe, denari, spade– e ciascun seme ha carte numerate da 1 a 10 (al lettore la scelta della variante grafica dei semi). Si estrae una carta a caso: gli eventi "esce un asso" (cioè un 1) ed "esce una carta di denari" sono indipendenti? ■

Vediamo ora come si estende la nozione di indipendenza al caso di più eventi, cominciando con tre. Affinché A, B e C siano indipendenti, occorre anzitutto che siano soddisfatte le tre eguaglianze

$$\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B), \qquad \mathbb{P}(A \cap C) = \mathbb{P}(A) \cdot \mathbb{P}(C), \qquad \mathbb{P}(B \cap C) = \mathbb{P}(B) \cdot \mathbb{P}(C),$$

cioè che siano a due a due indipendenti, ma deve anche esse soddisfatta l'eguaglianza

$$\mathbb{P}(A\cap B\cap C)=\mathbb{P}(A)\cdot\mathbb{P}(B)\cdot\mathbb{P}(C).$$

Non basta infatti che siano a due a due indipendenti, come è mostrato nell'esempio seguente.

■ **Esempio 3.9** Sull'insieme $\Omega=\{1,2,3,4\}$ munito della distribuzione uniforme di probabilità, gli eventi $A=\{1,2\},B=\{1,3\}$ e $C=\{2,3\}$ sono a due a due indipendenti. Tuttavia, valgono anche

$$\mathbb{P}(A\cap B\mid C)=0\neq\frac{1}{4}=\mathbb{P}(A\cap B),\quad \mathbb{P}(C\mid A\cap B)=0\neq\frac{1}{2}=\mathbb{P}(C),$$

ovvero conoscere l'evento C fornisce informazione su $A\cup B$ e viceversa. Non è ragionevole dunque dire che A,B,C sono globalmente indipendenti. ■

Per un numero arbitrario di eventi, si dà la seguente:

Definizione 3.4.2 Assegnati n eventi $A_1,\dots,A_n$, questi si dicono indipendenti se per ogni intero k con $2\leq k\leq n$ e per ogni scelta di interi $1\leq i_1<i_2<\ldots<i_k\leq n$, vale l'eguaglianza

$$\mathbb{P}\left(A_{i_1}\cap\cdots\cap A_{i_k}\right)=\mathbb{P}\left(A_{i_1}\right)\ldots\mathbb{P}\left(A_{i_k}\right)$$

Quando il numero di eventi cresce, il numero di eguaglianze da verificare sale notevolmente[3]. A priori questo appare essere un problema teorico, soprattutto nella descrizione probabilistica di un esperimento ripetuto più volte nelle medesime condizioni (che sarà uno dei nostri obiettivi principali): ci attendiamo infatti che gli eventi associati a ripetizioni distinte siano indipendenti. La complicazione è però solo apparente: eventi (ed in seguito variabili aleatorie) indipendenti sono facilmente costruiti considerando spazi prodotto. Ne vediamo un esempio paradigmatico con il risultato che segue.

Proposizione 3.4.1 Si consideri

$$\Omega=\{a=(a_1,\dots,a_n)\mid a_i=0,1\}=\{0,1\}^n,\quad \mathscr{F}=\mathscr{P}(\Omega),$$

su cui definiamo, per ogni singolo $a=(a_1,\dots,a_n)\in\Omega$,

$$\mathbb{P}(\{a\})=p^{\#\{i:a_i=1\}}(1-p)^{\#\{i:a_i=0\}}=p^{\sum_{i=1}^n a_i}(1-p)^{n-\sum_{i=1}^n a_i}.$$

Lo spazio $(\Omega,\mathscr{F},\mathbb{P})$ è di probabilità, e gli eventi

$$A_i=\{a\in\Omega:a_i=1\},\quad i=1,\dots,n,$$

sono tutti indipendenti tra di loro, così come i loro complementari A_i^c.

Lo spazio di probabilità suddetto descrive ad esempio n lanci di una moneta, in generale non equilibrata se $p\neq 1/2$. Nel caso di una moneta equilibrata, $p=1/2$, siccome i due esiti di un lancio hanno la stessa probabilità, ogni stringa di risultati ha la stessa probabilità di accadere, e $\mathbb{P}$ è la distribuzione uniforme su $\Omega=\{0,1\}^n$.

Dimostrazione. È sufficiente mostrare che vale, per ogni $k=0,1,\dots,n$,

$$\mathbb{P}\left(B_k\right)=p^k,\quad B_k=\{a\in\Omega:a_{n-k}=\cdots=a_n=1\},\quad B_0=\Omega$$

(sono gli eventi che fissano le ultime k coordinate). Scegliendo $k=0$ si mostra che $\mathbb{P}(\Omega)=1$, quindi lo spazio $(\Omega,\mathscr{P}(\Omega),\mathbb{P})$ è di probabilità. Inoltre, per verificare l'indipendenza degli eventi A_i dobbiamo considerare le intersezioni

$$A_{i_1}\cap\cdots\cap A_{i_k}=\{a\in\Omega:a_{i_1}=\cdots=a_{i_k}=1\}$$

[3] Per n eventi le eguaglianze da verificare sono 2^n-n-1.

per ogni scelta della famiglia di indici $i_1, \dots, i_k$. Non è difficile convincersi che riordinando gli indici (questo non cambia le probabilità degli eventi come si vede dalla definizione di $\mathbb{P}$) si ottiene $\mathbb{P}(A_{i_1} \cap \cdots \cap A_{i_k}) = \mathbb{P}(B_k)$. Vale quindi

$$\mathbb{P}(A_{i_1} \cap \cdots \cap A_{i_k}) = \mathbb{P}(B_k) = p^k = \mathbb{P}(B_1)^k = \mathbb{P}(A_{i_1}) \cdots \mathbb{P}(A_{i_k}),$$

(usando a destra il ragionamento per $k = 1$) da cui la tesi.

Calcoliamo quindi la probabilità di B_k:

$$\begin{aligned}\mathbb{P}(B_k) &= \sum_{a \in B_k} \mathbb{P}(\{a\}) = \sum_{a_1, \dots a_{n-k} = 0,1} \mathbb{P}(\{(1, \dots 1, a_{k+1}, \dots a_n)\}) \\ &= \sum_{a_1, \dots a_{n-k} = 0,1} p^k p^{\sum_{i=1}^{n-k} a_i} (1-p)^{n - \sum_{i=1}^{n-k} a_i} = p^k \sum_{h=0}^{n-k} \binom{n-k}{h} p^h (1-p)^{n-k-h} = p^k,\end{aligned}$$

in cui passando dalla prima alla seconda riga abbiamo usato il fatto che ci sono $\binom{n-k}{h}$ scelte delle entrate $a_1, \dots a_{n-k}$ in cui esattamente h sono uguali a 1. ■

Esercizio 3.14 Si lanciano due monete equilibrate, e poi se ne lancia una truccata come segue: esce testa se i primi due lanci sono concordi, croce altrimenti. Introdurre uno spazio di probabilità per descrivere l'esperimento, e verificare che gli eventi $A = \{\text{testa al primo lancio}\}$, $B = \{\text{testa al secondo lancio}\}$, $C = \{\text{testa al terzo lancio}\}$ sono a due a due indipendenti ma non sono globalmente indipendenti. ■

NB La terminologia può *erroneamente* indurre a pensare che l'indipendenza probabilistica sia legata al concetto di causalità. Quest'ultimo, in effetti, nell'ambito della Statistica o del calcolo delle Probabilità non ha una definizione univoca nè una generalmente accettata.

Come mostra l'esercizio precedente, due eventi possono essere indipendenti anche in presenza di una qualche relazione causale (il primo lancio determina assieme al secondo l'esito del terzo). Viceversa, due eventi possono essere dipendenti anche in assenza di una relazione causale. Ad esempio, i dinosauri sono estinti e, per quanto ne sappiamo, nessuno di loro sapeva leggere: dato un certo fossile di dinosauro gli eventi "appartiene a una specie estinta" e "appartiene a una creatura che non sapeva leggere" si verificano sempre assieme, ovvero non sono indipendenti, e tuttavia l'analfabetismo non si annovera tra le cause dell'estinzione dei dinosauri.

3.5 Probabilità sulla retta reale

Introduciamo in questo paragrafo due classi di esempi di probabilità sulla retta reale $\Omega = \mathbb{R}$. Questi esempi *non sono esaustivi* (come vedremo nel prossimo capitolo), però nelle applicazioni ci si riduce praticamente sempre a questi casi.

Probabilità discreta

Abbiamo già sostanzialmente discusso la prima classe di esempi: una *probabilità discreta* (o atomica) è una probabilità sullo spazio $\Omega = \mathbb{R}$ con la σ-algebra $\mathscr{F} = \mathscr{P}(\mathbb{R})$, che sia concentrata su una successione (finita o numerabile) di punti $x_1, x_2, \dots \in \mathbb{R}$[4]. Posto $p_i = p(x_i) = \mathbb{P}(x_i)$, vale

$$\mathbb{P}(A) = \sum_{i : x_i \in A} p(x_i), \quad \forall A \subseteq \mathbb{R}. \tag{3.1}$$

[4] In questo caso in effetti potremmo semplicemente ridurci a $\mathscr{F} = \mathscr{P}(\{x_1, x_2, \dots\}) \subset \mathscr{P}(\mathbb{R})$, ma non c'è problema a considerare tutti i sottoinsiemi di $\mathbb{R}$, a differenza dell'esempio successivo.

Definizione 3.5.1 Si chiama *funzione di massa* o anche *densità discreta* della probabilità discreta $\mathbb{P}$ la funzione $p(x_i) = \mathbb{P}(x_i)$.

La densità discreta soddisfa $p(x_i) \geq 0$ e $\sum_{i=1,2,\dots} p(x_i) = 1$. Viceversa, date una successione di punti $x_1, x_2, \dots$ in $\mathbb{R}$ e una funzione $p(x_i)$ di tali punti che soddisfa $p(x_i) \geq 0$ e $\sum_{i=1,2,\dots} p(x_i) = 1$, la formula (3.1) definisce un'unica probabilità discreta $\mathbb{P}$ su $\Omega = \mathbb{R}$ avente $p(x_i)$ per densità discreta. In particolare, grazie alla formula (3.1), per conoscere una probabilità discreta basta conoscere i valori sui quali è concentrata (cioè $x_1, x_2, \dots$) e i numeri $p_i = p(x_i)$.

Si può anche pensare di definire la funzione di massa $p(x) = \mathbb{P}(x)$ su tutta la retta (naturalmente sarà eguale a 0 fuori dei punti $x_1, x_2, \dots$) e allora la sola funzione di massa identifica la probabilità.

Probabilità definite da densità

Prima di affrontare la seconda classe di esempi, riportiamo il solo enunciato del modo in cui matematicamente viene risolto il problema sollevato nell'esempio 3.4.

Teorema 3.5.1 Esiste una σ-algebra $\mathscr{F} \subset \mathscr{P}(\mathbb{R})$ (che *non* coincide con $\mathscr{P}(\mathbb{R})$) tale che tutti gli intervalli (a,b), $-\infty \leq a \leq b \leq +\infty$ (incluse quindi le semirette) appartengono ad $\mathscr{F}$. Inoltre, esiste una funzione $\lambda : \mathscr{F} \to \mathbb{R} \cup \{\infty\}$ che è σ-additiva (nel senso della Definizione 3.1.2) e tale che, per ogni $-\infty \leq a \leq b \leq +\infty$,

$$\lambda((a,b)) = \lambda((a,b]) = \lambda([a,b)) = \lambda([a,b]) = b - a.$$

In effetti, esistono più σ-algebre con le suddette proprietà, ma questo ai nostri fini non è rilevante: quello che conta è poter misurare tutti i segmenti (incluse le semirette) e sottoinsiemi prodotti da essi con semplici operazioni insiemistiche (quelle consentite dalla definizione di σ-additività). Chiameremo gli elementi di $\mathscr{F}$ *insiemi misurabili*. Intersecando tutti gli elementi di $\mathscr{F}$ con l'intervallo $[0,1]$ otteniamo i sottoinsiemi misurabili di quest'ultimo, che sono una σ-algebra sulla quale possiamo definire la probabilità $\mathbb{P}(A) = \lambda(A)$ per ogni $A \subset [0,1]$ misurabile, in modo che

$$\mathbb{P}((a,b)) = |b-a|, \quad \forall a,b \in [0,1].$$

Vale la pena notare che λ (come di conseguenza la probabilità definita dall'ultima equazione) assegna lunghezza nulla ai singoli punti, ovvero $\lambda(x) = \lambda([x,x]) = x - x = 0$. Lo stesso vale per ogni sottoinsieme $A \subset \mathbb{R}$ con al più numerabili elementi: questa è una conseguenza immediata della σ-additività.

NB **Una premessa importante.** Nel seguito faremo diffusamente uso di integrali di funzioni sulla retta reale. Ai fini del rigore matematico è necessario in questo contesto introdurre la nozione di integrale secondo Lebesgue e le sue proprietà. Ciò va oltre lo scopo di queste note, per cui nel seguito ogni integrale e l'integrabilità delle funzioni possono essere intesi nel senso di Riemann. Ometteremo tutti i dettagli che richiedono ulteriore discussione teorica, facendone però debitamente menzione. Essi non sono infatti dettagli trascurabili nella Teoria della Probabilità: il lettore sia conscio che tali omissioni comportano precise limitazioni nei nostri argomenti che vanno tenute a mente.

Definizione 3.5.2 Si chiama densità di probabilità sulla retta reale una funzione non-negativa $f : \mathbb{R} \to [0, +\infty)$, integrabile e tale che $\int_{-\infty}^{+\infty} f(x)dx = 1$. Ad ogni densità di probabilità si associa un'unica probabilità sulla σ-algebra degli insiemi misurabili di $\mathbb{R}$ definita da:

$$\forall A \in \mathscr{F}, \quad \mathbb{P}(A) = \int_A f(x)dx.$$

Perchè questa sia una buona definizione va controllato che $\mathbb{P}$ così definita sia una probabilità nel senso della Definizione 3.1.2. Anzitutto, $\mathbb{P}(\mathbb{R}) = \int_{\mathbb{R}} f(x)dx = 1$ per ipotesi, ed inoltre se $A \cap B = \emptyset$ si ha

$$\mathbb{P}(A \cup B) = \int_{A\cup B} f(x)dx = \int_A f(x)dx + \int_B f(x)dx = \mathbb{P}(A) + \mathbb{P}(B).$$

Omettiamo il controllo della σ-additività, per il quale sono necessari risultati sull'integrazione secondo Lebesgue (in particolare, il *Lemma di Beppo-Levi* o di convergenza monotona).

L'Esempio 3.4 (un numero scelto a caso tra 0 e 1) è un caso particolare di probabilità associata a una densità, nel quale la densità è definita da

$$f(x) = \begin{cases} 1 & 0 \le x \le 1, \\ 0 & \text{altrove.} \end{cases}$$

NB Come discusso in quel caso particolare, la probabilità definita da una densità non può essere costruita su tutti i sottinsiemi di $\mathbb{R}$, ma solo sugli insiemi misurabili. Nelle applicazioni e negli esempi non capiterà mai di incontrare un insieme non misurabile: d'ora innanzi scriveremo $A, B, \ldots \subseteq \mathbb{R}$ assumendo sempre che siano misurabili.

Vale in generale per le probabilità definite da densità l'osservazione fatta nell'Esempio 3.4 sulla probabilità di un singolo punto: se X ha densità f,

$$\mathbb{P}(X = t) = \mathbb{P}_X(t) = \int_{\{t\}} f(x)dx = 0, \quad \forall t \in \mathbb{R},$$

e vale più in generale $\mathbb{P}(A) = 0$ per ogni $A \subset \mathbb{R}$ con al più numerabili elementi.

Esercizio 3.15 — Una probabilità non discreta e non definita da densità. Introduciamo la seguente notazione: dato un insieme $S \subset \mathbb{R}$ la sua *funzione indicatrice* è

$$\chi : \mathbb{R} \to \{0,1\}, \quad \chi_S(x) = \begin{cases} 1 & x \in S, \\ 0 & x \notin S. \end{cases}$$

Si consideri lo spazio di probabilità così definito: $\Omega = [0,1]$, $\mathscr{F}$ i sottoinsiemi misurabili e, per ogni $A \in \mathscr{F}$,

$$\mathbb{P}(A) = \frac{1}{2}|A| + \frac{1}{2}\chi_{\{2\}}(A).$$

Si mostri che questa è una misura di probabilità, e si osservi che non è discreta, ma non è nemmeno definita tramite una densità. ∎

3.6 Esercizi

Esercizio 3.16 Da un mazzo di 40 carte napoletane (quattro semi: bastoni, coppe, denari, spade; ciascuno seme ha carte da 1 a 10) vengono estratte tre carte, senza rimpiazzo. Qual è la probabilità che le prime due siano di denaro e la terza di coppe? Qual è la probabilità che escano esattamente due carte di denaro (in qualcunque ordine)? ∎

Esercizio 3.17 Tre turisti (tra loro estranei) arrivano in un paese con cinque alberghi, avendo prenotato ciascuno un albergo in modo del tutto casuale. a) Qual è la probabilità che si trovino tutti in alberghi differenti? b) Qual è la probabilità che si trovino tutti nello stesso albergo? ■

Esercizio 3.18 In una classe di 10 alunni, di cui 6 donne e 4 uomini, vengono estratte a sorte 5 persone. Qual è la probabilità che, tra le persone estratte, ci siano esattamente 3 donne? Qual è la probabilità che ci siano almeno 4 donne? ■

Esercizio 3.19 Una ditta classifica le sue consegne come in città o fuori città e come urgenti o non urgenti. Sappiamo che il 50% delle consegne è urgente, il 40% è in città e il 20% è urgente e fuori città. Calcolare le probabilità che una consegna sia rispettivamente: a) urgente e in città; b) urgente e fuori città; c) urgente, sapendo che è in città. Gli eventi "la consegna è urgente" e "la consegna è in città" sono indipendenti? ■

Esercizio 3.20 Secondo le previsioni meteo, domani a Pisa ci sarà: pioggia con probabilità del 70%, vento con probabilità del 50%, pioggia ma non vento con probabilità del 40%. Calcolare le probabilità di: a) pioggia o vento; b) pioggia e vento; c) né pioggia né vento; d) vento, sapendo che pioverà. ■

Esercizio 3.21 Un'urna contiene 10 biglie, di cui 5 rosse e 5 blu. Effettuiamo 4 estrazioni con reimmissione. Qual è la probabilità che almeno 3 biglie su 4 siano rosse?

Una seconda urna contiene 8 biglie rosse e 2 blu. Scegliamo un'urna a caso ed estraiamo da questa 4 biglie con reimmissione.

- Qual è la probabilità che almeno 3 siano rosse?
- Se almeno 3 biglie estratte sono rosse, qual è la probabilità che abbiamo scelto la prima urna?
- Gli eventi "rossa alla prima estrazione" e "rossa alla seconda estrazione" sono indipendenti?

■

Probabilità Condizionata

Esercizio 3.22 In una famiglia ci sono due figli. Se almeno uno dei due è femmina, qual è la probabilità che siano entrambi femmine? ■

Esercizio 3.23 In due lanci di un dado equilibrato, gli eventi "1 al primo lancio" e "somma degli esiti dei due lanci $= 3$" sono indipendenti? ■

Esercizio 3.24 Nella città di Urbopoli, si stima che, tra coloro che abitualmente utilizzano gli autobus pubblici, il 20% lo faccia sistematicamente senza pagare il biglietto. Tra coloro che non pagano il biglietto, il 70% sono individui di età inferiore a 15 anni, mentre tra coloro che lo pagano chi ha meno di 15 anni rappresenta il 40%.

1. Si sceglie a caso un individuo (nella popolazione di coloro che utilizzano gli autobus); quanto vale la probabilità che si tratti di un individuo di età inferiore a 15 anni?
2. Se l'individuo scelto ha meno di 15 anni, quanto vale la probabilità che egli paghi abitualmente il biglietto?

3. Se l'individuo scelto ha 15 anni o più, quanto vale la probabilità che egli abitualmente non paghi il biglietto?

■

Esercizio 3.25 Un'assicurazione auto classifica i guidatori come prudenti o imprudenti. Un guidatore prudente ha almeno un incidente l'anno con probabilità dell'1%, un guidatore imprudente con probabilità del 5%. Il 60% dei guidatori assicurati è classificato come prudente.

- Qual è la probabilità che un assicurato abbia almeno un incidente in un dato anno?
- Se un assicurato ha avuto almeno un incidente, qual è la probabilità che sia classificato come prudente?

■

Esercizio 3.26 Un furto è stato commesso a Urbopoli. Sulla base degli indizi raccolti, il commissario è convinto che il sig. Rossi sia colpevole di tale furto con probabilità del 40% (cioè, su 100 casi simili, il sig. Rossi sarebbe colpevole in 40 casi). Non ci sono altri sospettati. Il commissario viene ora a conoscenza di un nuovo indizio: il colpevole ha i capelli biondi, come il sig. Rossi. Da una statistica, emerge che il 20% degli abitanti di Urbopoli ha i capelli biondi. Come cambia la valutazione del commissario circa la probabilità di colpevolezza del sig. Rossi? ■

Esercizio 3.27 Un'urna contiene 5 palline, di cui 4 rosse e 1 blu. Si consideri il seguente esperimento. Si estrae una prima pallina dall'urna. Se questa prima pallina estratta è blu, l'esperimento termina. Se invece la prima pallina estratta è rossa, la pallina non viene reinserita nell'urna, ma se ne aggiunge un'altra che è rossa con probabilità $3/4$ e blu con probabilità 1/4, e successivamente si estrae nuovamente una pallina dall'urna. Dopo la seconda estrazione l'esperimento termina in ogni caso.

- Qual è la probabilità che durante l'esperimento venga estratta una pallina blu? Ripetendo 10 volte l'esperimento dall'inizio, determinare la probabilità di estrarre una pallina blu per 3 volte.
- Sapendo che la pallina blu è stata estratta alla seconda estrazione, qual è la probabilità che la pallina inserita nell'urna dopo la prima estrazione fosse blu?

■

Esercizio 3.28 Un sacchetto contiene 10 monete, di cui 8 "oneste" (ossia una faccia è Testa e una faccia Croce, e nel lancio della moneta le due facce sono equiprobabili) e 2 con entrambe le facce uguali a Testa. L'esperimento consiste nell'estrarre una moneta dal sacchetto e lanciarla: se esce Testa l'esperimento è concluso, altrimenti si reinserisce la moneta e si ripete l'operazione.

1. Determinare la probabilità che durante l'esperimento vengano eseguiti k lanci, con $k \in \mathbb{N}$.
2. Sapendo che l'esito Testa non si è avuto nei primi 10 lanci, determinare la probabilità di successo in meno di 13 lanci.
3. Supponiamo che al primo lancio sia uscita Testa, qual è la probabilità che sia stata estratta dal sacchetto una moneta onesta?

■

Esercizio 3.29 La distribuzione in Italia dei gruppi sanguigni è la seguente:

	0	A	B	AB
+	40	36	7.5	2.5
-	7	6	1.5	0.5

(ad esempio, il 40% degli individui è di tipo 0+).

- Qual è la probabilità che l'individuo estratto abbia Rh+?
- Qual è la probabilità che abbia Rh+, sapendo che ha gruppo AB?
- Gli eventi "Rh+" e "gruppo sanguigno AB" sono indipendenti?

■

Esercizio 3.30 Vengono lanciati $n \geq 1$ dadi a sei facce: qual è la probabilità che la somma dei punti di tutti i dadi sia divisibile per 7?

Suggerimento: i casi $n = 1, 2$ sono facili, per il caso n-esimo si condizioni sul risultato dei primi $n-1$ dadi, ottenendo una formula ricorsiva. ■

Esercizio 3.31 — Difficile. Si elegge il rappresentante degli studenti al corso di laurea di Scienze Scientifiche. Il candidato Avogadro vince con a voti, mentre il candidato Bohr viene sconfitto ottenendo $b < a$ voti. Si mostri che la probabilità che durante lo spoglio dei voti Avogadro sia stato in testa a Bohr in ogni momento è data da $\frac{a-b}{a+b}$.

Suggerimento: Condizionare sull'ultimo voto scrutinato e procedere per ricorsione. ■